TSR 当前构对规则与训练配置

候选生成、自评分、偏好对筛选与 DPO 超参说明。范围为修复重复加载后的单份数据实验，重点描述迭代 1 中的 M1、Mf1 与四组 M2。

核心配置：DPO 总序列上限 2048 tokens；prompt 上限配置为 512 tokens；每阶段训练 1 epoch；有效 batch size 为 32 对偏好样本。

01 模型角色与训练关系

模型	本轮角色	初始化关系
M0	初始 SFT 模型；提供过去回答	已完成的 SFT checkpoint
M1	当前模型；生成回答并统一评分	上一轮从 M0 训练得到
Mf1	future 模型；提供未来回答	从 M1 出发，在 D1 上训练
M2	本轮最终模型；比较四种 D2 设置	各组均从同一个 M1 出发

Mf1 和 M2 的起点都是 M1。先构造 D1 并训练 Mf1，再用 Mf1 生成 future 回答、构造 D2，最后从 M1 初始化训练各组 M2。

02 候选生成与统一评分

回答来源	每题数量	评分模型	用途
当前 M1	7 条	M1	chosen 与 rejected 候选
过去 M0（SFT）	7 条	M1	rejected 候选
未来 Mf1	7 条	M1	chosen 候选

迭代 1 使用 qa2 的 5,000 个问题。候选生成采用 vLLM，温度 1.0、top_p 为 1.0、每条回答最多生成 1024 tokens，并沿用上游聊天模板与 EOS 停止设置。

三类回答均由 M1 按上游五分制提示评分，每个回答生成一次判断，取第一个可解析的“Score: 数值”；解析失败记为 0。分数用于选择偏好对，不按评分概率加权，也不直接作为连续奖励权重传入 DPO。GPT-4o 仅用于外部 AlpacaEval 评测。

03 D1 如何得到 Mf1

每题的 chosen 取 M1 的最高分回答；rejected 在 M1 和 M0 的回答中取最低分，两个模型最低分相同时优先 M1。D1 保留 chosen 与 rejected 同分的样本。四组共用同一份 D1 和同一个 Mf1；Mf1 实际训练 5,000 对、156 步。

偏好对筛选与训练长度

四组只改变最终 M2 所用 D2 的 future 替换条件与同分对过滤开关。D1、Mf1、候选回答和评分均固定。

04 D2 的 chosen 与 rejected

选择项	规则	跨模型同分时
chosen：≥ 设置	比较 M1 与 Mf1 各自最高分回答；选分数高者	优先未来 Mf1
chosen：> 设置	仅当 Mf1 最高分严格更高时，替换 M1 的回答	保留当前 M1
rejected：四组一致	比较 M1 与 M0 各自最低分回答；选分数低者	优先当前 M1

同一个模型内部出现多个最高分或最低分回答时，取生成列表中第一个。Mf1 不进入 rejected 候选池。构对阶段不按回答长度排序，不额外设置分差阈值，也不对 chosen/rejected 文本做相同内容去重。

M2 设置	chosen/rejected 同分时	D2 条数	优化步数
≥ + 保留同分	保留整对样本	5,000	156
> + 保留同分	保留整对样本	5,000	156
≥ + 去同分	丢弃整对样本	4,770	149
> + 去同分	丢弃整对样本	4,770	149

“去同分”的准确条件是只保留 chosen 分数严格高于 rejected 分数的样本；本轮删除 230 对。“保留同分”仍将 chosen 当正样本、rejected 当负样本，不额外给它们设置平局标签。

05 长度上限与截断行为

项目	配置与实际行为
总序列长度	max_length = 2048；分别限制 prompt + chosen、prompt + rejected，不是将两个回答合并后共用一个长度预算。
Prompt 长度	max_prompt_length = 512；超过时保留最后 512 个 token，即从左侧裁剪。即使总长未超过 2048，也先执行此限制。
回答长度	未单独设置 max_completion_length。生成阶段上限是 1024 tokens，训练时重新分词并追加 EOS；训练序列受总长 2048 兜底限制。
超出总长时	prompt 与单条回答拼接后，从序列右侧截断至 2048 tokens。
DPO 计分范围	只累计回答部分的 token log-prob；system/user 所在 prompt 不计入回答 log-prob。

BOS 细节：TRL 先将 prompt 截到最后 512 tokens，仓库补丁随后补 BOS。因此实际 prompt 最多可到 513 tokens；最终总序列上限仍为 2048。这是当前 TRL 0.12.2 与仓库补丁组合后的行为。

DPO 超参与核验依据

以下参数用于本轮各个 DPO 阶段。四组 M2 的优化配置一致，训练步数随过滤后的数据条数变化。

参数	当前值
训练方式	全参数训练，不使用 LoRA
Mf1 / M2 初始化与参考模型	均从同一个 M1 初始化；reference 为冻结的 M1
Loss / DPO ß	标准 sigmoid DPO；ß = 0.1
Label smoothing / Dropout	Label smoothing = 0；禁用 dropout（库默认）
训练轮数	1 epoch；每份偏好数据只加载一次
学习率 / 调度器	5e-7；cosine
Warmup ratio	0.1
优化器	AdamW，配置名 adamw_torch
Adam 参数	ß1 = 0.9；ß2 = 0.999；epsilon = 1e-8（库默认）
Weight decay / 梯度裁剪	Weight decay = 0；max grad norm = 1.0（库默认）
每卡 batch / GPU 数	每卡 1 对偏好样本；2 张 A800 80 GB
梯度累积 / 有效 batch	累积 16 次；有效 batch 为 32 对偏好样本
精度 / 分布式	BF16 混合精度；DeepSpeed ZeRO-3；不做 CPU offload
Gradient checkpointing	开启；use_reentrant = False
训练随机种子	42
权重保存与选择	训练结束保存最终权重；不按评测结果挑选 checkpoint
回答 log-prob 聚合	对回答 token 求和，不改成按回答长度求平均

06 数据加载与版本

DPO 只加载隔离目录中的一份 train.json；上游校验副本不进入训练集。保留上游 HumanEval 去污染检查，本轮实际训练条数与构对条数一致。该修复不改变 SFT 的多文件加载方式。

环境：TRL 0.12.2、Transformers 4.46.3、PyTorch 2.5.1、DeepSpeed 0.15.4、Accelerate 1.1.1、vLLM 0.6.4.post1。迭代 0 的 Mf0、M1 均从 M0 初始化，且各训练 5,000 对、156 步。

07 核验来源与范围

运行记录：2026-11-04 / 05 的实际训练日志、trainer_state、数据加载记录及 Mf1 来源审计；对应 work-tsr-singlecopy-20261104。

仓库代码：Qst137/tsr-reproduction，提交 1f80f17；构对为 src/build_pairs.py，配置生成为 src/make_cfg.py，BOS 修复为 patches/0001-dpo-prepend-bos.patch。

上游代码：TemporalSelfRewarding/TSR，提交 020266a；DPO 模板为 settings/sr/config/dpo/config_full_iter0.yaml；长度处理核对 TRL v0.12.2 源码。